项目成果 · PROJECT OUTCOMES

在线实验的决策审计

Decision Audit of Online Experiments — Randomization Integrity, Winner's Curse and Cross-Deployment Transferability

32,485 个真实 A/B 实验

150,815 个实验臂 · 5.38 亿次曝光

个人独立项目 · Python · MIT

> 把研究对象锁定在一个很少被审计的决策上——**「实验赢了，到底该不该上线？」** 结论是：平台以为赢了的方案，有 **28.7%** 其实无法区分；而赢到的优势，只有 **15.5%** 能迁移到下一次投放。

01 核心成果

1. **分流失衡可被无先验地检出并定位到天。**仅用曝光分配数据做卡方检验 + 似然比区间扫描，自行定位出平台的随机化故障窗口 **2013-06-24 ~ 2014-01-12**，与官方 2024 年事后披露的窗口相比精确率 **98.5%**、召回率 **100%**。
2. **真实效应存在，且模型经得起样本外检验。**τ^2=0.052，真实点击率的 90% 区间为 1.04%—2.18%；留一臂后验预测的 95% 区间实测覆盖率 **94.1%**（名义 95%），后验方差无系统性偏差。
3. **赢家诅咒：平台汇报的提升超过真实上限。**平台会汇报 **+32.6%**，高于「事后知道哪个方案最好」的 **+29.4%**；被选中方案的真实提升只有 **+24.2%**，其中约 4.4% 是选择偏差。
4. **（核心）「最优文案」的优势大部分无法迁移。**用被重复投放的素材做天然重复测量：实验内的臂间优势只有约 **15.5%** 可复现到下一次投放，最优收缩系数 **0.14**，仅为分层模型隐含值 0.75 的 1/5。
5. **收缩不改变「选谁」，只告诉你「有多确定」。**经验贝叶斯选择与「取最高点击率」在 **99.84%** 的实验里结论相同；真正的问题是置信度——被上线方案的「最优臂后验概率」中位数仅 0.62，**28.7%** 的实验低于 0.5。
6. **「检测到失衡就丢弃实验」缺乏依据。**四项可证伪检验（过度离散、效应量、剂量反应、决策质量）均未发现失衡实验有实质危害，而丢弃的代价是照旧分析的 **6.5 倍**（约 2,520 万次曝光）。

02 关键图表

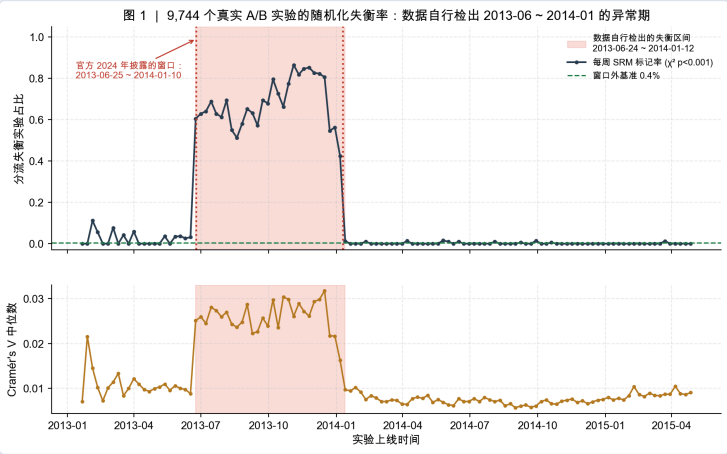


图 1 | 9,744 个真实 A/B 实验的随机化失衡率。数据在没有任何先验的情况下自行检出 2013–06 至 2014–01 的异常期——与官方 11 年后披露的窗口相差 1–2 天。

03 样本外确认（13 项关键指标 12 项复现）

指标	开发样本（9,744 实验）	confirmatory 样本外（22,741 实验）	相对偏差
失衡率	15.21%	15.52%	2.1%
留一臂 95% 预测覆盖率	0.9408	0.9413	0.06%
观测提升 / 诚实提升	+32.56% / +24.24%	+32.52% / +23.99%	0.1% / 1.0%
自行检出的故障窗口	2013–06–24 ~ 2014–01–12	2013–06–24 ~ 2014–01–12	完全相同

04 交付物

技术报告 19 页 · 13 图 · 含局限与稳健性 | **Python 包** exptdecide（9 组单元测试） | **一键复现** python –m src.run_all（实测 45 秒）
项目主页 gongsjie3–cyber.github.io/ab–decision–audit | **GitHub** github.com/gongsjie3–cyber/ab–decision–audit

方法要点：解析高斯经验贝叶斯后验（闭式解、无 MCMC）；τ^2 的四条独立估计路径；Helmert 对照的精确方差分解；配对评价协议；注册报告式分析纪律。

数据来源：Upworthy Research Archive (CC BY 4.0，32,487 个实验全部公开)
Matias et al. (2021) Scientific Data 8:155